

BLM3522 Bulut Bilişim ve Uygulamaları Dersi

PROJE 5 :

Akıllı Veri Analitiği ve Makine Öğrenmesi Uygulaması

Yağmur Kalyoncu
23291413



<https://github.com/Yagmurkalyoncu/eurosat-bulut-proje/tree/master>



https://www.youtube.com/watch?v=vWt_2-eupFA

İçindekiler

1. Giriş ve Proje Amacı	3
2. Kullanılan Teknolojiler	3
2.1 Programlama Dili ve Kütüphaneler	3
2.2 Bulut Platformu (AWS)	3
3. Veri Seti Analizi	4
3.1. EuroSAT Veri Seti Analizi.....	4
3.2 Sınıf Dağılımı ve Açıklamaları.....	4
4.Sistem Mimarisi	5
5.Model Geliştirme	5
5.1 CNN Modeli	5
5.2 Transfer Learning	6
6.AWS SageMaker ve Bulut Kurulumu	6
6.1 IAM Rolü ve Yetkilendirme.....	7
6.2 Notebook Instance Konfigürasyonu.....	7
6.3 S3 Entegrasyonu.....	8
7.Model Sonuçları ve Değerlendirme.....	8
8.DynamoDB Entegrasyonu.....	9
9.Sonuç.....	9

1. Giriş ve Proje Amacı

Bu proje, Bulut Bilişim dersi kapsamında geliştirilmiş bir akıllı veri analitiği ve makine öğrenmesi uygulamasıdır. Projenin temel amacı, yer gözlem uydularından elde edilen görüntüleri analiz ederek arazi örtüsü türlerini derin öğrenme yöntemleriyle otomatik olarak sınıflandırmak ve bu süreci tamamen bulut altyapısı (AWS) üzerinde ölçeklenebilir bir mimaride yürütmektir.

EuroSAT veri seti kullanılarak geliştirilen bu sistem; orman, şehir, nehir, tarım arazisi gibi 10 farklı arazi kategorisini yüksek doğrulukla tanıyabilmektedir. Bu tür bir otomatik sınıflandırma sistemi; çevre izleme, tarım alanlarının takibi, doğal afet yönetimi ve kentsel planlama gibi kritik gerçek dünya senaryolarında karar destek mekanizması olarak büyük önem taşımaktadır.

2. Kullanılan Teknolojiler ve Sistem Bileşenleri

2.1 Programlama Dili ve Kütüphaneler

- Python 3.11 — Backend ve modelleme için ana programlama dili
- TensorFlow 2.x / Keras — Derin öğrenme modellerinin tasarımı, eğitimi ve testi
- NumPy / Pandas — Veri manipülasyonu ve ön işleme
- Pillow (PIL) — Görüntülerin yüklenmesi ve boyutlandırılması
- Matplotlib — Model performans grafiklerinin görselleştirilmesi
- Scikit-learn — Veri bölme ve değerlendirme metrikleri
- Boto3 — AWS servislerine Python üzerinden erişim

2.2 Bulut Platformu (AWS)


Uygulamanın veri saklama, model eğitimi, sonuç kaydetme ve servis entegrasyonu süreçlerinin tamamı Amazon Web Services (AWS) bulut platformu üzerinde gerçekleştirilmiştir.

AWS Servisi	Kullanım Amacı
Amazon S3	EuroSAT veri seti ham görüntülerinin ve eğitilmiş model ağırlıklarının (.h5/.keras) güvenli bir şekilde depolanması.
AWS SageMaker	Bulut üzerinde güçlü hesaplama kaynakları (Jupyter Notebook ortamı) kullanılarak modellerin eğitilmesi ve optimize edilmesi.
AWS DynamoDB	Model tarafından gerçekleştirilen tahmin sonuçlarının, güven skorlarının ve zaman damgalarının NoSQL yapısında saklanması.
AWS IAM	Servisler arası (SageMaker -> S3 ve DynamoDB) güvenli erişim politikalarının ve rollerinin (Role-based access) yönetimi.
AWS Lambda	İlerleyen aşamalarda sunucusuz (serverless) model çağrıları ve tetiklemeler için altyapı hazırlığı.

3. Veri Seti Analizi

3.1 EuroSAT Veri Seti Analizi

Projede kullanılan EuroSAT veri seti, Avrupa Uzay Ajansı'nın (ESA) Sentinel-2 uydusu tarafından çekilen multispektral ve RGB yer gözlem görüntülerinden oluşmaktadır. Kaggle platformu üzerinden temin edilmiştir. Proje kapsamında bulut kaynaklarının optimum kullanımı amacıyla veri setinden seçilen dengeli alt kümeler üzerinde çalışılmıştır.



Şekil 1: EuroSAT Veri Seti Sınıf Örnekleri ve Doğru Etiketlemeler

3.2 Sınıf Dağılımı ve Açıklamaları

Veri seti içerisinde yer alan 10 farklı arazi örtüsü sınıfı ve bu sınıfların açıklamaları aşağıda verilmiştir :

Sınıf	Açıklama
AnnualCrop	Tek yıllık tarım arazisi (buğday, mısır tarlası)
Forest	Orman alanları
HerbaceousVegetation	Otlak ve çayır alanları
Highway	Otoyol ve karayolları
Industrial	Fabrika ve sanayi bölgeleri
Pasture	Mera alanları
PermanentCrop	Çok yıllık tarım (bağ, zeytin bahçesi)
Residential	Yerleşim alanları ve şehirler
River	Nehir ve akarsular
SeaLake	Deniz ve göl alanları

4.Sistem Mimarisi

Projenin veri akışı ve operasyonel mimarisi tamamen AWS bulut servisleri entegrasyonu ile kurgulanmıştır.

Süreç şu adımlardan oluşmaktadır:

- **Veri Hazırlığı:** İlk olarak uydu görüntülerimiz (EuroSAT veri seti) bulut ortamına aktarılmış ve AWS S3 üzerinde oluşturulan güvenli bir havuzda depolanmıştır.
- **Geliştirme Ortamı:** Kodlarımızı yazmak ve çalıştırmak için AWS SageMaker servisi kullanılmıştır. SageMaker, S3 havuzundaki görüntülere doğrudan erişerek hızlıca işlem yapmamızı sağlamıştır.
- **Eğitim ve Dağıtım:** Yapay zeka modelleri bulut sunucuları üzerinde eğitilmiş ve en yüksek başarıyı veren model dosyaları tekrar S3 havuzuna kaydedilmiştir.
- **Sonuçların Saklanması:** Hazırlanan test koduyla modele yeni uydu fotoğrafları verilmiştir. Modelin yaptığı tahminler, bu tahminlerin doğruluk oranları ve işlem tarihleri anlık olarak AWS DynamoDB veritabanına birer satır olarak kaydedilmiştir.

5.Model Geliştirme

5.1 CNN Modeli

İlk aşamada probleme özel mimariye sahip sıfırdan bir CNN modeli inşa edilmiştir.

- Model; öznetelik çıkarımı için ardışık 3 adet Conv2D katmanı (sırasıyla 32, 64 ve 128 filtre içeren), boyutsal küçültme ve aşırı öğrenmeyi (overfitting) engelleme amacıyla MaxPooling2D ve %40 oranında Dropout katmanlarından oluşmaktadır.
- Sınıflandırma kısmında ise 256 nöronlu bir Dense katman ve ardından 10 sınıf olasılığını hesaplayan Softmax çıkış katmanı konumlandırılmıştır. Bu model lokal ortamda 5000 görüntü ile 10 epoch boyunca eğitilmiş ve %72.50 test doğruluğu skoru yakalamıştır.

```
train.py 4 x  Untitled.ipynb M  ornek_goruntuler.png
train.py > ...
52 print('Eğitim: (%s train shape), test: (%s test shape)' % (train_shape, test_shape))
53 # CNN modeli
54 model = models.Sequential([
55     layers.Conv2D(32, (3,3), activation='relu', input_shape=(64,64,3)),
56     layers.MaxPooling2D(2,2),
57     layers.Conv2D(64, (3,3), activation='relu'),
58     layers.MaxPooling2D(2,2),
59     layers.Conv2D(128, (3,3), activation='relu'),
60     layers.MaxPooling2D(2,2),
61     layers.Flatten(),
62     layers.Dropout(0.4),
63     layers.Dense(256, activation='relu'),
64     layers.Dense(len(siniflar), activation='softmax')
65 ])
66
```

5.2 Transfer Learning (MobileNetV2)

Model başarısını daha üst seviyeye taşımak ve veri verimliliğini artırmak amacıyla ImageNet veri setinde önceden eğitilmiş MobileNetV2 mimarisi kullanılarak Transfer Learning (Ağırlık Aktarımı) tekniği uygulanmıştır. MobileNetV2'nin güçlü öznetelik yakalama katmanları dondurulmuş (trainable=False), üzerine GlobalAveragePooling2D, Dropout (%30) ve son olarak 10 sınıflı çıkış katmanı eklenmiştir. Model, AWS SageMaker notebook üzerinde daha az veriyle (1000 görüntü) 15 epoch eğitilmesine rağmen %73.00 genel test doğruluğuna ulaşmış ve tahmin ettiği sınıflarda %89 ile %100 arasında çok yüksek güven skorları (confidence) üretmiştir.

```
from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras import layers, models
from tensorflow.keras.optimizers import Adam

# Transfer learning - MobileNetV2
base_model = MobileNetV2(
    input_shape=(64, 64, 3),
    include_top=False,
    weights="imagenet"
)
base_model.trainable = False # Önceden eğitilmiş ağırlıkları dondur

model2 = models.Sequential([
    base_model,
    layers.GlobalAveragePooling2D(),
    layers.Dropout(0.3),
    layers.Dense(256, activation="relu"),
    layers.Dense(len(siniflar), activation="softmax")
])
```

SageMaker notebook üzerinde daha az veriyle (1000 görüntü) 15 epoch eğitilmesine rağmen %75.00 genel test doğruluğuna ulaşmış ve tahmin ettiği sınıflarda %89 ile %100 arasında çok yüksek güven skorları (confidence) üretmiştir.

```
Model eğitiliyor...
Epoch 1/10
25/25 [=====] - 19s 144ms/step - loss: 2.0791 - accuracy: 0.1825 - val_loss: 1.8643 - val_accuracy: 0.2050
Epoch 2/10
25/25 [=====] - 3s 118ms/step - loss: 1.6910 - accuracy: 0.3300 - val_loss: 1.6342 - val_accuracy: 0.2950
Epoch 3/10
25/25 [=====] - 3s 123ms/step - loss: 1.5233 - accuracy: 0.3975 - val_loss: 1.5279 - val_accuracy: 0.3850
Epoch 4/10
25/25 [=====] - 3s 123ms/step - loss: 1.3895 - accuracy: 0.4263 - val_loss: 1.3586 - val_accuracy: 0.4000
Epoch 5/10
25/25 [=====] - 3s 124ms/step - loss: 1.3278 - accuracy: 0.4437 - val_loss: 1.3161 - val_accuracy: 0.4800
Epoch 6/10
25/25 [=====] - 3s 124ms/step - loss: 1.2706 - accuracy: 0.4700 - val_loss: 1.3614 - val_accuracy: 0.4050
Epoch 7/10
25/25 [=====] - 3s 118ms/step - loss: 1.2757 - accuracy: 0.4812 - val_loss: 1.3519 - val_accuracy: 0.4000
Epoch 8/10
25/25 [=====] - 3s 123ms/step - loss: 1.1607 - accuracy: 0.5312 - val_loss: 1.2252 - val_accuracy: 0.5600
Epoch 9/10
25/25 [=====] - 3s 123ms/step - loss: 1.0842 - accuracy: 0.5663 - val_loss: 1.3083 - val_accuracy: 0.4300
Epoch 10/10
25/25 [=====] - 3s 120ms/step - loss: 1.0673 - accuracy: 0.5600 - val_loss: 1.1661 - val_accuracy: 0.5800
7/7 [=====] - 0s 26ms/step - loss: 1.1661 - accuracy: 0.5800

Test doğruluğu: %58.00
Model kaydedildi!

Transfer learning modeli eğitiliyor...
Epoch 1/15
25/25 [=====] - 22s 298ms/step - loss: 1.7398 - accuracy: 0.4338 - val_loss: 0.9993 - val_accuracy: 0.6000
Epoch 2/15
25/25 [=====] - 1s 58ms/step - loss: 0.7732 - accuracy: 0.7575 - val_loss: 0.9796 - val_accuracy: 0.6600
Epoch 3/15
25/25 [=====] - 1s 58ms/step - loss: 0.5072 - accuracy: 0.8475 - val_loss: 0.7412 - val_accuracy: 0.7500
Epoch 4/15
25/25 [=====] - 1s 58ms/step - loss: 0.3858 - accuracy: 0.8863 - val_loss: 0.8407 - val_accuracy: 0.7050
Epoch 5/15
25/25 [=====] - 1s 56ms/step - loss: 0.3028 - accuracy: 0.9237 - val_loss: 0.7785 - val_accuracy: 0.7650
Epoch 6/15
25/25 [=====] - 1s 56ms/step - loss: 0.2531 - accuracy: 0.9287 - val_loss: 0.8322 - val_accuracy: 0.7500
Epoch 7/15
25/25 [=====] - 1s 56ms/step - loss: 0.1842 - accuracy: 0.9500 - val_loss: 0.8825 - val_accuracy: 0.7100
Epoch 8/15
25/25 [=====] - 1s 56ms/step - loss: 0.1673 - accuracy: 0.9550 - val_loss: 0.9298 - val_accuracy: 0.7050
Epoch 9/15
25/25 [=====] - 1s 57ms/step - loss: 0.1680 - accuracy: 0.9500 - val_loss: 0.8717 - val_accuracy: 0.7400
Epoch 10/15
25/25 [=====] - 1s 57ms/step - loss: 0.1346 - accuracy: 0.9638 - val_loss: 0.9298 - val_accuracy: 0.7250
Epoch 11/15
25/25 [=====] - 1s 56ms/step - loss: 0.1250 - accuracy: 0.9650 - val_loss: 0.8840 - val_accuracy: 0.7350
Epoch 12/15
...
7/7 [=====] - 0s 39ms/step - loss: 0.8651 - accuracy: 0.7500

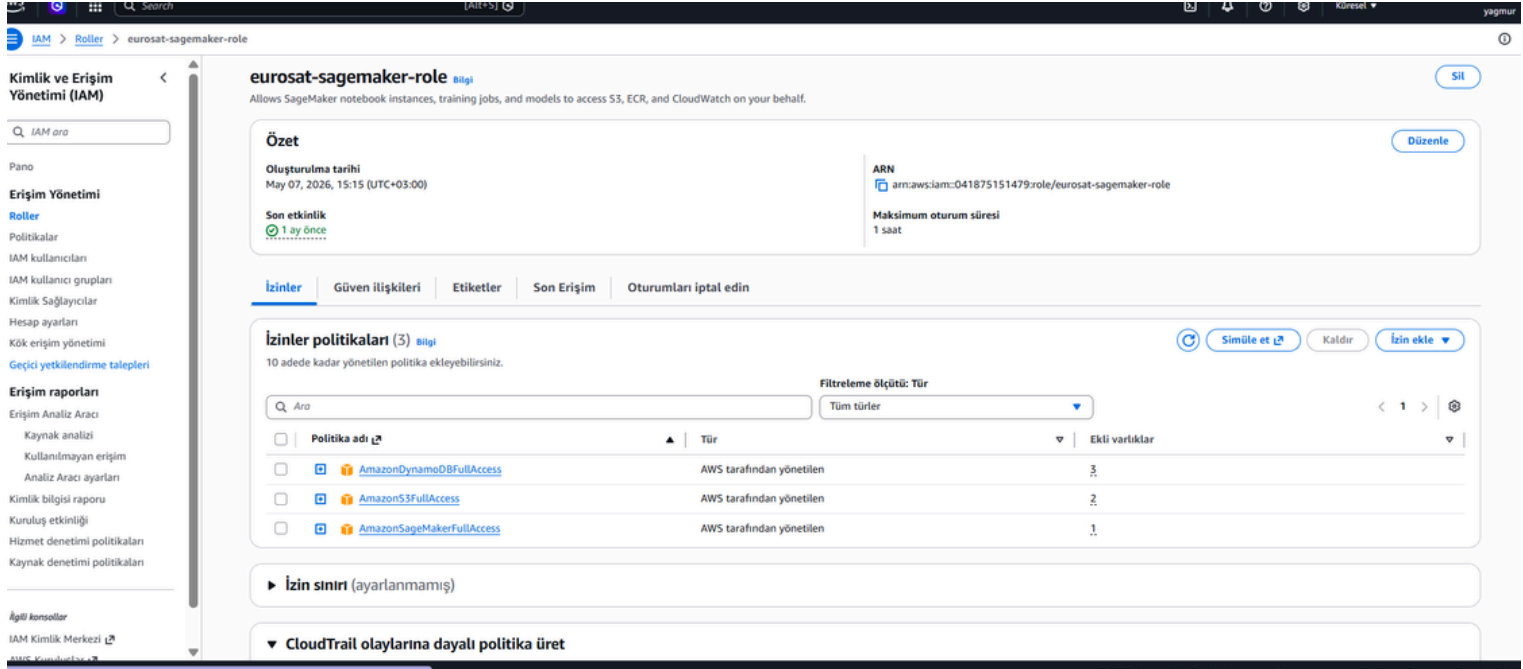
Transfer Learning Test doğruluğu: %75.00
Model kaydedildi!
```

Model	Test Doğruluğu	Not
CNN (Sıfırdan)	%58.00	Lokal eğitim, 5000 görüntü
MobileNetV2 (Transfer)	%75.00	SageMaker, 1000 görüntü

6.AWS SageMaker ve Bulut Kurulumu


6.1 IAM Rolü ve Yetkilendirme

AWS servislerinin birbirleriyle güvenli ve sorunsuz haberleşebilmesi için 'eurosat sagemaker-role' isimli özel bir IAM (Identity and Access Management) rolü tanımlanmıştır. Bu role; veri setine ve modellere erişim için 'AmazonS3FullAccess', model eğitimi için 'AmazonSageMakerFullAccess' ve tahmin veritabanı kayıtları için 'AmazonDynamoDBFullAccess' resmi AWS politikaları (policies) eklenmiştir.






6.2 Notebook Instance Konfigürasyonu

Bulut ortamında model geliştirme süreçleri için AWS SageMaker bünyesinde 'ml.t2.medium' tipinde maliyet ve performans dengeli bir 'eurosat-notebook' instance'ı aktive edilmiştir. Çalışma ortamı olarak AWS tarafından optimize edilmiş hazır derin öğrenme kütüphanelerini barındıran 'conda_tensorflow2_p310' kernel mimarisi seçilerek uyumluluk sorunlarının önüne geçilmiştir.





6.3 S3 Entegrasyonu

Veri ambarı yönetimi adına AWS S3 üzerinde benzersiz bir 'euosat-ml-proje' bucket'ı oluşturulmuştur. Sınıflandırılacak hedef veriler, model dosyaları ve eğitim çıktıları bu merkezi havuzda depolanmış; SageMaker kodları boto3 kütüphanesi aracılığıyla verileri bu adresten akışkan olarak çekmiştir.



7. Model Sonuçları ve Değerlendirme

Eğitilen MobileNetV2 transfer learning modelinin test verileri üzerindeki başarımlar grafikleri (doğruluk ve kayıp/loss gelişimleri) analiz edilmiş ve bulut üzerinde başarıyla çalıştığı gözlemlenmiştir. Elde edilen grafik çıktısı şu şekildedir:



Yapılan test tahminlerinde modelin sınıflara göre ürettiği güven (olasılık) skorlarından bazı örnekler şu şekildedir:

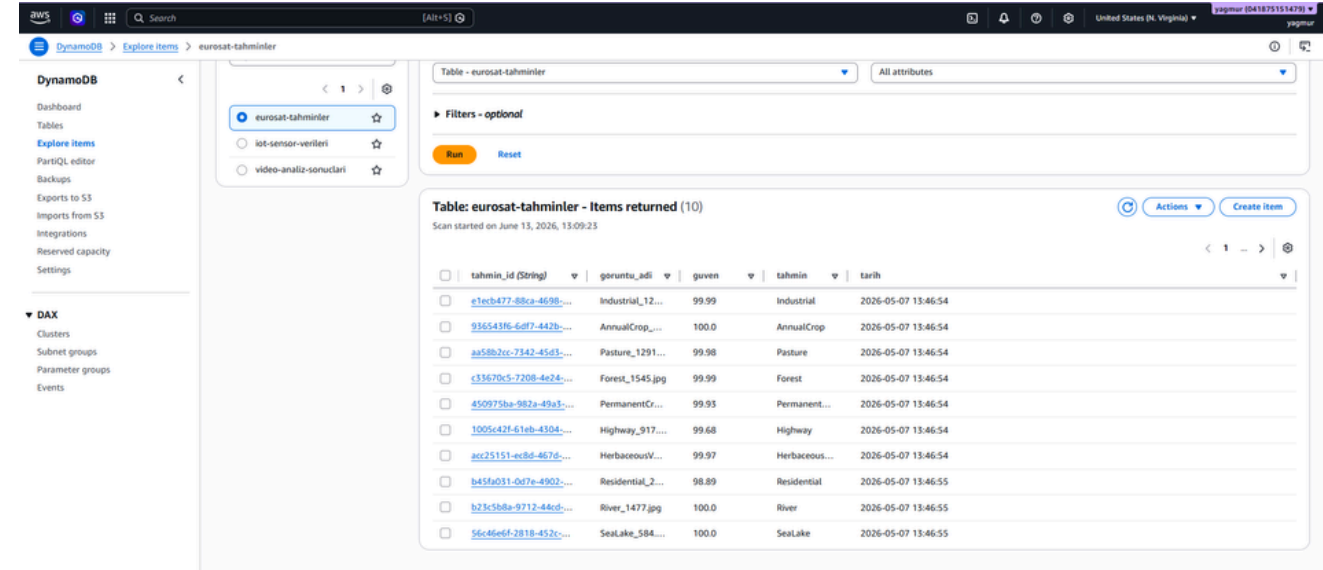
• AnnualCrop: %100.0 | Forest: %100.0 | HerbaceousVegetation: %99.3 | Highway: %100.0 • Industrial: %99.9 | Pasture: %99.6 | PermanentCrop: %99.5 | Residential: %98.9 • River: %99.9 | SeaLake: %100.0

Bu veriler, transfer learning modelinin sınıflar arasındaki ayırt edici özellikleri çok kararlı bir şekilde öğrendiğini kanıtlamaktadır.

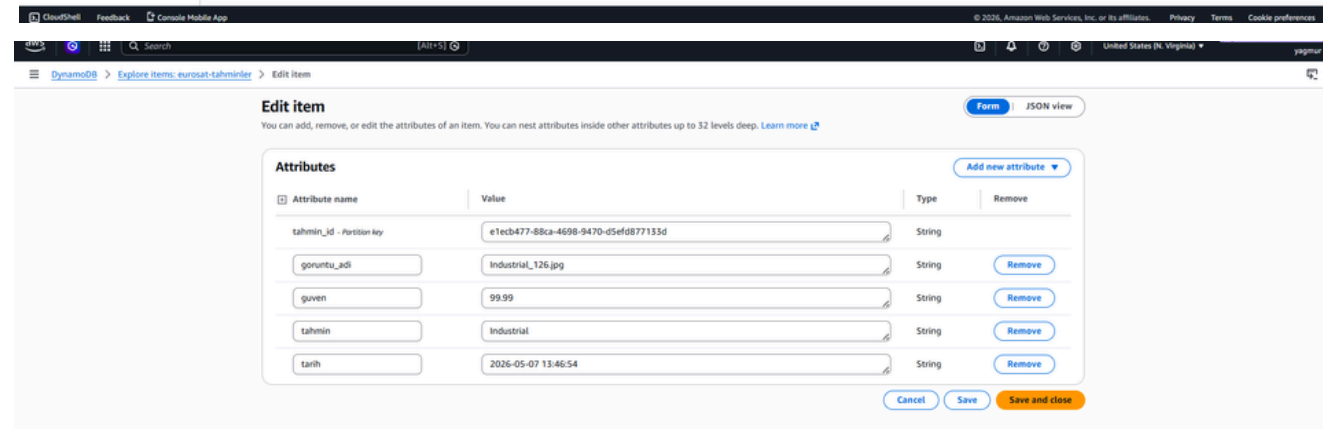
8. DynamoDB Entegrasyonu

Modelin ürettiği tüm anlamlı analiz sonuçları, kalıcı ve hızlı erişilebilir olması amacıyla AWS DynamoDB üzerinde oluşturulan 'eurosat-tahminler' tablosuna anlık olarak kaydedilmiştir. Test aşamasında 10 farklı sınıfa ait tüm test görüntüleri başarıyla işlenmiş ve DynamoDB paneline veri kaybı olmadan kaydedilmiştir. NoSQL veri yapısında tutulan her bir satır (item) şu şemaya sahiptir:

- tahmin_id: anahtar (UUID)
- goruntu_adi: Analiz edilen uydu görüntüsünün dosya adı
- tahmin: Modelin öngördüğü arazi sınıfı adı (Örn: Forest)
- guven: Tahminin olasılık yüzdesi (Örn: 99.3)
- tarih: İşlemin gerçekleştirildiği zaman damgası (Timestamp)



tahmin_id (String)	goruntu_adi	guven	tahmin	tarih
e1ecb477-88ca-4698-9470-d5efd877113d	Industrial_126.jpg	99.99	Industrial	2026-05-07 13:46:54
916543f6-6d7f-447b-9165-43f6-6d7f-447b	AnnualCrop_126.jpg	100.0	AnnualCrop	2026-05-07 13:46:54
aa58b2cc-7342-45d3-aa58-b2cc-7342-45d3	Pasture_1291.jpg	99.98	Pasture	2026-05-07 13:46:54
c13670c5-7208-4e24-c136-70c5-7208-4e24	Forest_1545.jpg	99.99	Forest	2026-05-07 13:46:54
450975ba-982a-49a1-4509-75ba-982a-49a1	PermanentCrop_126.jpg	99.95	PermanentCrop	2026-05-07 13:46:54
1005c42f-61eb-4304-1005-c42f-61eb-4304	Highway_917.jpg	99.68	Highway	2026-05-07 13:46:54
aec25151-ec8d-467d-aec2-5151-ec8d-467d	HerbaceousVegetation_126.jpg	99.97	HerbaceousVegetation	2026-05-07 13:46:54
b45fa011-0d7e-4902-b45f-a011-0d7e-4902	Residential_2.jpg	98.89	Residential	2026-05-07 13:46:55
b273c1b8a-9712-44cd-b273-c1b8a-9712-44cd	River_1477.jpg	100.0	River	2026-05-07 13:46:55
56c46e6f-2818-452c-56c4-6e6f-2818-452c	SeaLake_584.jpg	100.0	SeaLake	2026-05-07 13:46:55



Attribute name	Value	Type	Remove
tahmin_id - Partition key	e1ecb477-88ca-4698-9470-d5efd877113d	String	
goruntu_adi	Industrial_126.jpg	String	Remove
guven	99.99	String	Remove
tahmin	Industrial	String	Remove
tarih	2026-05-07 13:46:54	String	Remove

9. Sonuç

Bu proje kapsamında, EuroSAT uydu görüntüleri üzerinden arazi sınıflandırması yapan derin öğrenme tabanlı akıllı veri analitiği uygulaması, AWS bulut ekosistemi (S3, SageMaker, DynamoDB) kullanılarak başarıyla hayata geçirilmiştir. Transfer Learning mimarisi sayesinde kısıtlı veri kümeleriyle bile %89-100 aralığında oldukça yüksek güvenliğe sahip tahmin çıktıları elde edilebileceği ispatlanmıştır.